



Evaluación Unidad I

Preprocesamiento y Almacenamiento de Datos

AbejaNet Revival — Sistema IoT de Monitoreo de Colmenas

Asignatura:

Extracción de Conocimiento en Bases de Datos

Carrera:

Ingeniería en Desarrollo y Gestión de Software

Grupo: IDGS 16

Periodo: Mayo – Agosto 2026

Equipo de Trabajo

Marco Antonio Gómez Olvera	Programador de la Aplicación Móvil
Orlando Rubio Cabrera	Encargado de IoT
Sandra Zoé Cabrera Velázquez	Encargada de Documentación
Israel Gómez Bonilla	Desarrollador de la Aplicación Web

Unidad Tecnológica de Querétaro (UTEQ)

Querétaro, junio de 2026

Índice

1. Contexto del Caso de Estudio	2
1.1. Arquitectura del Sistema	2
1.2. Colmenas Monitoreadas	2
2. SA — Evidencia del Saber: Arquitectura del Data Warehouse	3
2.1. Esquema de Data Warehouse — Estrella (Star Schema)	3
2.2. Tipos y Fuentes de Datos	3
2.3. Técnicas de Limpieza de Datos	3
2.4. Parámetros de Configuración del Data Warehouse (PostgreSQL local) . . .	3
2.5. Repositorio Técnico	5
3. DE — Evidencia de Desempeño: Proceso de Limpieza Paso a Paso	6
3.1. Problemas de Calidad Identificados	6
3.2. Resultados del Pipeline — Antes vs. Después	6
3.3. Evidencia Visual — Paso 1: Corrección de Formatos	6
3.4. Evidencia Visual — Paso 4: Diagnóstico de Outliers (IQR)	7
3.5. Estadísticas Descriptivas Post-limpieza (Paso 7)	7
3.6. Archivos Generados	8
4. AU — Evidencia Autónoma: Selección de Características Avanzada	9
4.1. Variable Objetivo	9
4.2. Método 1 — Correlación de Pearson	9
4.3. Método 2 — Umbral de Varianza	12
4.4. Método 3 — Test Chi-Cuadrado (χ^2)	12
4.5. Método 4 — Importancia con Random Forest (150 árboles)	13
4.6. Resumen de Selección	14
4.7. Dataset Final Optimizado	14
5. Archivos Entregados	15

1 Contexto del Caso de Estudio

AbejaNet Revival es una plataforma IoT para monitoreo en tiempo real de colmenas de abejas (*Apis mellifera*). El sistema integra sensores ESP32 instalados en las colmenas para recopilar variables ambientales (temperatura, humedad, peso, decibelios y lluvia), un backend Node.js/Express con base de datos PostgreSQL, una aplicación móvil React Native/Expo y un panel web de administración.

La tabla `lecturas_ambientales` de la base de datos operacional constituye la fuente principal de datos de esta evaluación. Dado que el servidor de producción (Render) no estaba activo durante el periodo de desarrollo, los datos se generaron de forma sintética con el script `00_generar_datos.py`, replicando la lógica de simulación del archivo original `backend/generate_mock_data.js` del proyecto.

1.1 Arquitectura del Sistema

- **Sensores ESP32:** Envían lecturas vía POST `/api/sensor-data` cada 10 minutos con autenticación por clave API.
- **Backend Node.js/Express:** Recibe, valida y persiste los datos en PostgreSQL alojado en Render.
- **Aplicación móvil:** Consume la API REST con autenticación JWT, mostrando gráficas de tendencias por colmena.
- **Panel web:** Gestión de usuarios, apiarios, colmenas y alertas.

1.2 Colmenas Monitoreadas

Apiario	Colmena	MAC	Tipo Sensor
Apiario Principal	Colmena Alfa Ppal	AA:BB:CC:11:22:33	Temperatura/Humedad
Apiario Principal	Colmena Gamma Ppal	AA:BB:CC:11:22:44	Multisensor
Apiario Laboratorio	Colmena Beta Lab	A2:04:2A:B9:C1:D9	Multisensor

Tabla 1: Inventario de colmenas y sensores del sistema AbejaNet

2 SA — Evidencia del Saber: Arquitectura del Data Warehouse

2.1 Esquema de Data Warehouse — Estrella (Star Schema)

Se optó por el **Esquema en Estrella** debido a que la tabla de hechos (`fact_lecturas_ambientales`) contiene métricas numéricas bien definidas, las dimensiones tienen cardinalidad estable (Slowly Changing Dimensions tipo 1), y el modelo ofrece mayor eficiencia en consultas OLAP que el esquema copo de nieve.

Tabla 2: Tabla de Hechos: `fact_lecturas_ambientales`

Columna	Tipo	Descripción
<code>id_lectura</code>	BIGSERIAL PK	Clave surrogate autogenerada
<code>sk_sensor</code>	INTEGER FK	→ <code>dim_sensor</code>
<code>sk_tiempo</code>	INTEGER FK	→ <code>dim_tiempo</code>
<code>sk_colmena</code>	INTEGER FK	→ <code>dim_colmena</code>
<code>sk_apiario</code>	INTEGER FK	→ <code>dim_apiario</code>
<code>temperatura</code>	DECIMAL(5,2)	°C interior de la colmena
<code>humedad</code>	DECIMAL(5,2)	% de humedad relativa
<code>peso</code>	DECIMAL(6,2)	kg totales de la colmena (NULL si no aplica)
<code>sonido</code>	DECIMAL(5,2)	dB de actividad sonora
<code>lluvia</code>	SMALLINT	1 = lluvia, 0 = sin lluvia
<code>alerta_temp</code>	SMALLINT	1 si temperatura > 35°C (calculado)

Granularidad: una fila representa la lectura de un sensor cada 15 minutos.

Tabla 3: Dimensiones del Data Warehouse

Dimensión	Clave PK	Atributos principales
<code>dim_tiempo</code>	<code>sk_tiempo</code>	<code>fecha_completa</code> , <code>año</code> , <code>mes</code> , <code>semana</code> , <code>dia_semana</code> , <code>hora</code> , <code>periodo_dia</code> , <code>es_noche</code> , <code>es_fin_semana</code> , <code>es_hora_activa_abejas</code>
<code>dim_sensor</code>	<code>sk_sensor</code>	<code>mac_address</code> , <code>tipo_sensor</code> , <code>estado</code> , <code>fecha_instalacion</code>
<code>dim_colmena</code>	<code>sk_colmena</code>	<code>nombre_colmena</code> , <code>descripcion</code> , <code>fecha_creacion</code>
<code>dim_apiario</code>	<code>sk_apiario</code>	<code>nombre_apiario</code> , <code>descripcion_general</code> , <code>coordenadas</code>

2.2 Tipos y Fuentes de Datos

2.3 Técnicas de Limpieza de Datos

2.4 Parámetros de Configuración del Data Warehouse (PostgreSQL local)

Tabla 4: Inventario de variables por tipo estadístico

Variable	Tipo	Escala	Rango / Valores
temperatura	Continua	Razón	[0, 45] °C
humedad	Continua	Razón	[40, 95] %
peso	Continua	Razón	[10, 30] kg
sonido	Continua	Razón	[40, 80] dB
lluvia	Discreta	Nominal	{0, 1}
tipo_sensor	Categórica	Nominal	Temperatura/Humedad, Multisensor
estado	Categórica	Ordinal	activo, mantenimiento, inactivo, no_asignado
hora	Discreta	Cíclica	[0, 23]
dia_semana	Discreta	Ordinal	[0, 6]
es_noche	Discreta	Nominal	{0, 1}
alerta_temp	Discreta	Nominal	{0, 1} (variable objetivo)

Tabla 5: Fuentes de datos del proyecto

Fuente	Tipo	Descripción
ESP32 → POST /api/sensor-data	Estructurada en tiempo real	Lecturas cada 10 min con cabecera X-API-Key
generate_mock_data.js	Sintética estructurada	Simulación de 30 días en Node.js
00_generar_datos.py	Sintética estructurada	Dataset de esta práctica con problemas de calidad intencionales
abeja_net_v4_postgres.sql	Relacional	Esquema oficial + datos semilla de la BD

Listing 1: Esquema y índices de optimización para el DW

```

CREATE SCHEMA abejanet_dw;

-- Indices principales para JOINS OLAP
CREATE INDEX idx_fact_sk_sensor ON fact_lecturas_ambientales (sk_sensor);
CREATE INDEX idx_fact_sk_tiempo ON fact_lecturas_ambientales (sk_tiempo);
CREATE INDEX idx_fact_sk_colmena ON fact_lecturas_ambientales (sk_colmena);
CREATE INDEX idx_dim_tiempo_fecha ON dim_tiempo (fecha_completa);
CREATE INDEX idx_dim_tiempo_hora ON dim_tiempo (hora, es_noche);

-- postgresql.conf recomendado para analisis local
-- shared_buffers = 512MB

```

Tabla 6: Técnicas de limpieza aplicadas y su justificación

Técnica	Justificación y Aplicación
Forward fill (ffill) por grupo	Variables de serie temporal: el valor más reciente del mismo sensor es la mejor estimación de un dato faltante. Respeta la autocorrelación temporal.
Eliminación de duplicados	Un sensor no puede tener dos lecturas en el mismo instante (<code>sensor_id</code> + <code>fecha_registro</code>). Duplicados exactos eliminados con <code>drop_duplicates</code> .
Reglas de negocio (outliers)	Temperatura fuera de $[0, 45]^{\circ}\text{C}$ o humedad fuera de $[0, 100]\%$ son físicamente imposibles $\rightarrow$ se invalidan como NaN y se reimputan.
Interpolación lineal (peso)	El peso de la colmena crece de forma gradual y predecible. La interpolación lineal es apropiada entre puntos cercanos.
Mapeo de formatos	lluvia podía llegar como <code>True/False</code> , <code>"si"/"no"</code> o <code>1/0</code> . Se normalizó todo a entero $\{0, 1\}$.
Eliminación de huérfanos	Registros sin <code>sensor_id</code> no pueden asociarse a ninguna colmena y se eliminan.

```
-- work_mem          = 64MB
-- effective_cache_size = 2GB
-- max_parallel_workers_per_gather = 4
```

2.5 Repositorio Técnico

El conjunto de datos preprocesado, los scripts y los archivos de log se encuentran en el repositorio público:

https://github.com/MarkG777/Evaluacion_BD

Los archivos entregados son: `data/raw/lecturas_crudas.csv` (datos crudos), `data/clean/lecturas` (datos limpios) y `data/clean/dataset_final_features.csv` (dataset optimizado AU).

3 DE — Evidencia de Desempeño: Proceso de Limpieza Paso a Paso

El script `02_de_limpieza_pipeline.py` aplica diez transformaciones sobre el dataset crudo y produce un log completo (`data/clean/log_limpieza.txt`) con evidencia cuantitativa de cada paso.

3.1 Problemas de Calidad Identificados

Tabla 7: Problemas de calidad presentes en `lecturas_crudas.csv`

Problema	Cantidad	Técnica aplicada
Nulos en <code>temperatura</code>	346 (4.06 %)	Forward fill por sensor
Nulos en <code>humedad</code>	438 (4.99 %)	Forward fill por sensor
Nulos en <code>sonido</code>	267 (3.04 %)	Forward fill por sensor
Outliers <code>temperatura</code> $>45^{\circ}\text{C}$ o $<0^{\circ}\text{C}$	76	Invalidar $\rightarrow$ NaN $\rightarrow$ reimputar
Outliers <code>humedad</code> $>100\%$	67	Invalidar $\rightarrow$ NaN $\rightarrow$ reimputar
Filas duplicadas (exactas)	127	<code>drop_duplicates()</code>
Duplicados <code>sensor+timestamp</code>	1	<code>drop_duplicates(subset)</code>
Formato incorrecto en <code>lluvia</code>	351 (4 %)	Maapeo normalizado a <code>int {0,1}</code>
Registros huérfanos sin <code>sensor_id</code>	68	Eliminación

3.2 Resultados del Pipeline — Antes vs. Después

Tabla 8: Evidencia cuantitativa de cada paso del pipeline

Paso	Técnica	Antes	Después	Δ
0	Carga del dataset crudo	—	8 769	—
1	Corrección de tipos y formatos	8 769	8 769	0 filas, 0 nulos
2	Eliminación de duplicados	8 769	8 641	−128 filas
3	Eliminación de huérfanos	8 641	8 573	−68 filas
4	Invalidación de outliers	8 573	8 573	+143 nulos
5	Imputación <code>ffill+bfill</code>	8 573	8 573	−1 164 nulos
6	Enriquecimiento temporal	13 cols	21 cols	+8 features
7	Validación final de rangos	—	OK	Sin errores
Total removidos		8 769	8 573	−196 (2.24 %)

3.3 Evidencia Visual — Paso 1: Corrección de Formatos

Listing 2: Salida real del PASO 1 – corrección de tipos

```
[1a] fecha_registro
      Tipo antes   : object (str)
      Tipo despues : datetime64[us]
      Fechas invalidas (NaT): 0

[1b] lluvia
      Valores antes  : ['False' 'no' 'True' 'si']
      Valores despues: [0 1]
      Tipo despues   : int8

[1c] sensor_id
      Tipo despues: Int64 (NaN conservados: 69)
```

3.4 Evidencia Visual — Paso 4: Diagnóstico de Outliers (IQR)

Listing 3: Salida real del PASO 4 – deteccion y tratamiento de outliers

```
[temperatura (diagnostico IQR)]
Q1=22.36 Q3=32.14 IQR=9.79
Limites IQR: [7.68, 46.82]
Outliers estadisticos: 86 (1.04%)
-> Regla de negocio: temperatura fuera de [0.0, 45.0] C -> NaN
-> Outliers invalidados: 76

[humedad (diagnostico IQR)]
Q1=53.35 Q3=70.67 IQR=17.32
Limites IQR: [27.37, 96.65]
Outliers estadisticos: 67 (0.82%)
-> Regla de negocio: humedad fuera de [0, 100]% -> NaN
-> Outliers invalidados: 67
```

3.5 Estadísticas Descriptivas Post-limpieza (Paso 7)

Listing 4: Salida real del PASO 7 – estadísticas descriptivas finales

	temperatura	humedad	peso	sonido
count	8573.000	8573.000	5710.000	8573.000
mean	27.195	61.955	15.910	57.679
std	5.104	9.157	0.737	8.509
min	0.040	44.270	14.440	44.000
25%	22.380	53.320	15.310	49.440
50%	27.190	62.010	15.910	60.770
75%	32.100	70.520	16.510	65.480
max	35.940	79.580	17.380	70.000

Distribucion por colmena:

Colmena Alfa Ppal	2863 lecturas
Colmena Gamma Ppal	2860 lecturas
Colmena Beta Lab	2850 lecturas

Validaciones de rango superadas: temperatura [0,45] OK | humedad [0,100] OK

Dataset limpio: 8573 filas x 21 columnas

3.6 Archivos Generados

- `data/raw/lecturas_crudas.csv` — 8 769 filas $\times$ 13 columnas (datos con suciedad intencional)
- `data/clean/lecturas_limpias.csv` — 8 573 filas $\times$ 21 columnas (dataset limpio + features temporales)
- `data/clean/log_limpieza.txt` — log completo de ejecución con evidencia de cada transformación

4 AU — Evidencia Autónoma: Selección de Características Avanzada

4.1 Variable Objetivo

Target: `alerta_temperatura` = 1 si `temperatura` > 35°C

Owens (1971) y Seeley (1985) documentan que por encima de 35°C las abejas de ventilación (*fanners*) se activan masivamente, lo que se manifiesta en un incremento del nivel sonoro, descenso de humedad interior y potencial pérdida de peso por enjambre. Distribución: 8 364 negativos (97.6 %) y 209 positivos (2.4 %).

4.2 Método 1 — Correlación de Pearson

La correlación de Pearson mide la relación lineal entre cada variable numérica y el target. Umbral de corte: $|r| \geq 0.02$. Ninguna feature fue descartada por este método — todas presentan alguna relación lineal con `alerta_temperatura`.




Figura 1: Matriz completa de correlación de Pearson (features candidatas + target)




Figura 2: Coeficiente de Pearson de cada feature con `alerta_temperatura`. Verde = conservar ($|r| \geq 0.02$).

4.3 Método 2 — Umbral de Varianza

Se descartaron features cuasi-constantes con varianza inferior a 0.01. Ninguna feature fue eliminada por este criterio, confirmando que todas tienen dispersión suficiente para aportar información al modelo.




Figura 3: Varianza de cada feature. La línea roja marca el umbral de 0.01.

4.4 Método 3 — Test Chi-Cuadrado (χ^2)

El test χ^2 evalúa si existe una asociación estadísticamente significativa entre cada variable discreta o categórica y el target (H_0 : independencia). Se rechaza H_0 cuando $p < \alpha = 0.05$.

Fig. 4 — Test Chi-Cuadrado ($\alpha = 0.05$)

Feature	χ^2 valor	p-valor	Resultado
es_noche	98.2280	0.000000	Significativo
tipo_sensor_enc	71.5408	0.000000	Significativo
periodo_dia_enc	16.5792	0.000047	Significativo
lluvia	0.9715	0.324318	No significativo
es_fin_semana	0.3314	0.564857	No significativo

Figura 4: Resultados del test χ^2 . Celdas verdes ($p < 0.05$) indican asociación significativa con el target.

Descartadas: lluvia ($p = 0.324$) y es_fin_semana ($p = 0.565$). La lluvia no presenta asociación significativa con alertas de temperatura porque los eventos de lluvia son independientes del ciclo térmico diario de la colmena.

4.5 Método 4 — Importancia con Random Forest (150 árboles)

Se entrenó un clasificador Random Forest con 150 árboles sobre las features supervivientes. Las features con importancia Gini inferior a 0.02 se descartaron.




Figura 5: Importancia Gini por feature. Verde = retenida (≥ 0.02), rojo = descartada.

4.6 Resumen de Selección

Tabla 9: Features finales seleccionadas y su justificación

Feature	Import. RF	Justificación
humedad	0.5316	Correlación inversa fuerte con temperatura ($r \approx -0.8$)
hora	0.1285	La temperatura sigue un ciclo coseno diario con máximo a media tarde
sonido	0.1224	Las abejas <i>fanners</i> incrementan la actividad sonora bajo estrés térmico
tipo_sensor_enc	0.0781	Los sensores Multisensor operan en colmenas con distintos microclimas
es_noche	0.0645	Proxy binario del ciclo día/noche; temperatura siempre inferior de noche
peso	0.0447	El enjambre por calor puede producir pérdida de peso detectable

Tabla 10: Resumen de reducción dimensional por método

Métrica	Valor
Features candidatas iniciales	12
Descartadas por Pearson ($ r < 0.02$)	0
Descartadas por varianza (< 0.01)	0
Descartadas por Chi-cuadrado ($p \geq 0.05$)	2
Descartadas por Random Forest (< 0.02)	4
Features conservadas	6
Reducción dimensional	50 %

4.7 Dataset Final Optimizado

El archivo `data/clean/dataset_final_features.csv` contiene $8\,573$ filas $\times$ 7 columnas (`humedad`, `hora`, `sonido`, `tipo_sensor_enc`, `es_noche`, `peso`, `alerta_temperatura`) y está listo para ser utilizado directamente en el entrenamiento de modelos de clasificación (XGBoost, Random Forest, LSTM).

5 Archivos Entregados

Tabla 11: Repositorio de archivos generados por la práctica

Archivo	Descripción
00_generar_datos.py	Genera el dataset sintético de 8 769 registros con problemas de calidad intencionales
01_sa_arquitectura_dw.md	Documento SA: diseño del Star Schema, inventario de fuentes y técnicas de limpieza
02_de_limpieza_pipeline.py	Pipeline DE de 10 pasos con evidencia cuantitativa antes/después en cada transformación
03_au_seleccion_caracteristicas.py	Selección AU: cuatro métodos estadísticos con generación de 5 figuras PNG
data/raw/lecturas_crudas.csv	Dataset crudo, 8 769 filas $\times$ 13 columnas
data/clean/lecturas_limpias.csv	Dataset limpio, 8 573 filas $\times$ 21 columnas
data/clean/dataset_final_features.csv	Dataset AU optimizado, 8 573 filas $\times$ 7 columnas
data/clean/log_limpieza.txt	Log completo del pipeline DE
data/clean/log_seleccion.txt	Log completo de la selección AU
figures/fig1 - fig5.png	Evidencia visual: heatmap, Pearson, varianza, Chi-cuadrado, Random Forest

Repositorio público: https://github.com/MarkG777/Evaluacion_BD